

→ ĐỀ THI VÒNG 2

DATATHON 2026

THE GRIDBREAKER

Breaking Business Boundaries

Tổ chức bởi

VinTelligence

VinUniversity Data Science & AI Club

Cuộc thi Khoa học Dữ liệu đầu tiên tại VinUniversity
Biến Dữ liệu thành Giải pháp cho Doanh nghiệp

Contents

1	Mô tả Dữ liệu	2
1.1	Giới thiệu	2
1.2	Tổng quan các bảng dữ liệu	2
1.3	Bảng Dimension	2
1.3.1	dim_listing — Danh mục tin đăng BĐS	2
1.3.2	Mã danh mục category	3
1.4	Bảng Fact	3
1.4.1	fact_listing_snapshot — Hiệu năng tin đăng theo ngày	3
1.4.2	fact_post_contact_interactions — Tổng hợp tương tác user × tin theo ngày	3
1.4.3	fact_user_events — Clickstream thô	4
1.5	Quan hệ giữa các bảng	5
1.6	Lưu ý chung	5
2	Hướng dẫn Truy cập & Sử dụng Dữ liệu	6
2.1	Tổng quan môi trường	6
2.2	Cấu trúc dữ liệu trên Google Cloud Storage	6
2.3	Kết nối từ Google Colab	6
2.3.1	Xác thực tài khoản	6
2.3.2	Đọc tập test	7
2.3.3	Đọc thử một file Parquet đơn lẻ	7
2.3.4	Quét toàn bộ thư mục (khuyến dùng cho big data)	7
2.4	Khuyến nghị về xử lý dữ liệu lớn	7
2.5	Điều khoản sử dụng dữ liệu	8
3	Đề Bài	9
3.1	Bối cảnh kinh doanh	9
3.2	Phần 1 — Trực quan hoá và Phân tích Dữ liệu	9
3.2.1	Một vài gợi ý mở (không bắt buộc)	9
3.3	Phần 2 — Mô hình Gợi ý (Recommender System)	10
3.3.1	Định nghĩa bài toán	10
3.3.2	Nhiệm vụ cốt lõi	10
3.3.3	Yêu cầu kép: chính xác + lành mạnh	10
3.3.4	Tư duy triển khai	10
3.3.5	Định dạng file dự đoán	10
3.3.6	Ràng buộc bài nộp	11
4	Tiêu chí Đánh giá	12
4.1	Triết lý chấm	12
4.2	Các trục đánh giá chính	12
4.3	Chỉ số leaderboard	12
4.4	Điều kiện loại bài	13
5	Hướng dẫn Nộp bài	14
5.1	Checklist nộp bài	14
5.1.1	Nộp kết quả dự đoán trên Kaggle	14
5.1.2	Bài thuyết trình	14
5.1.3	Form nộp bài thi Vòng Chung kết	14

Mô tả Dữ liệu

I Giới thiệu

Chợ Tốt là một trong những sàn thương mại điện tử C2C hàng đầu Việt Nam, với mảng bất động sản (BDS) bao gồm các phân khúc cho thuê, căn hộ chung cư, nhà ở, đất nền và dự án phát triển mới. Mô hình kinh doanh của nền tảng dựa trên **tạo lead** (lead-generation): doanh thu phát sinh khi người dùng tiến hành *liên hệ thực sự* với người bán — xem số điện thoại, mở cuộc trò chuyện, gọi qua Zalo hay nhắn tin SMS.

Bộ dữ liệu là bản chụp *star schema* thực tế của hệ thống Chợ Tốt trong giai đoạn 09/11/2025 – 07/05/2026, đã được **ẩn danh hoàn toàn** (mọi định danh đều là chuỗi SHA-256 hex). Tổng dung lượng nguyên gốc ~52 GB / 949 file Parquet. Bản phát hành cho thí sinh đã được cắt theo trục thời gian.

Định nghĩa tương tác tích cực (positive interaction):

Một sự kiện trong `fact_user_events` được xem là **tích cực** khi và chỉ khi:

$$\text{event_type} \in \{\text{view_phone}, \text{contact_chat}, \text{other_interaction}, \text{contact_zalo}, \text{contact_sms}\}.$$

Đây chính là **mục tiêu dự đoán** của cuộc thi: 4 loại sự kiện này thể hiện ý định mua/thuê thực sự, có giá trị thương mại cao và gắn liền với doanh thu của nền tảng. Các sự kiện duyệt trang (`pageview`, `other_interaction`) chỉ là tín hiệu nền (browsing noise) và **không được tính** là tích cực.

Phân chia dữ liệu cho bài toán khuyến nghị:

- `train/`: 09/11/2025 → 09/04/2026 (toàn bộ 4 bảng)
- `test/test_users.parquet`: danh sách `user_id` cần dự đoán
- `ground_truth/`: 10/04/2026 → 07/05/2026 — **giữ kín, thí sinh không được truy cập**

I Tổng quan các bảng dữ liệu

Table 1: Danh sách các bảng dữ liệu cung cấp cho thí sinh

#	Bảng	Lớp
1	<code>dim_listing</code>	Dimension
2	<code>fact_listing_snapshot</code>	Fact (daily)
3	<code>fact_post_contact_interactions</code>	Fact (daily)
4	<code>fact_user_events</code>	Clickstream
5	<code>test_users.parquet</code>	Test set

I Bảng Dimension

► `dim_listing` — Danh mục tin đăng BDS

Khoá chính: `item_id`. Một dòng tương ứng với một tin đăng.

Cột	Kiểu	Mô tả
item_id	str	Khoá chính (SHA-256)
seller_id	str	Mã người bán (SHA-256)
category	int	Mã danh mục: 1010/1020/1030/1040/1050
title	str	Tiêu đề tin (tiếng Việt, có thể chứa emoji)
seller_type	str	agent (môi giới) / private (cá nhân)
ad_type	str	sell (bán) / let (cho thuê)
ad_status	str	Trạng thái tin
area_sqm	float	Diện tích sử dụng (m ²)
bedrooms, bathrooms	float	Số phòng ngủ, phòng tắm
floors, width_m	float	Số tầng, mặt tiền (m)
direction	str	Hướng nhà tiếng Việt: Đông/Tây/Nam/Bắc + tổ hợp
legal_status	str	Tình trạng pháp lý (vd. <i>Đã có sổ, Sổ hồng riêng</i>)
house_type	str	Loại nhà (vd. <i>Nhà ngõ, hẻm, Nhà mặt phố</i>)
furnishing	str	Nội thất (vd. <i>Nội thất đầy đủ, Nhà trống</i>)
city_name	str	Tên tỉnh/thành (tiếng Việt)
district_name	str	Tên quận/huyện (tiếng Việt)
ward_name	str	Tên phường/xã (tiếng Việt)
project_id	str	Chỉ có với tin thuộc dự án mới
price_bucket	str	Khoảng giá (chuỗi tiếng Việt, vd. <i>3 tỷ - 5 tỷ, 5 triệu/tháng - 7 triệu/tháng</i>)
images_count	float	Số ảnh trong tin
posted_date	date	Ngày đăng tin
expected_expired_date	date	Ngày hết hạn dự kiến

► Mã danh mục category

Mã	Phân khúc
1010	Phòng trọ / căn hộ cho thuê (phòng trọ, mini studio)
1020	Căn hộ / chung cư
1030	Nhà ở (nhà phố, nhà hẻm, biệt thự...)
1040	Đất nền / bất động sản thương mại
1050	Dự án / căn hộ mở bán mới

I Bảng Fact

► fact_listing_snapshot — Hiệu năng tin đăng theo ngày

Một dòng = một (item_id, date).

Cột	Kiểu	Mô tả
item_id	str	FK → dim_listing
date	date	Ngày chụp
views_24h	float	Lượt xem trong 24h
contacts_24h	float	Lượt liên hệ trong 24h
listing_age_days	float	Tuổi tin tại ngày chụp (ngày)

► fact_post_contact_interactions — Tổng hợp tương tác user × tin theo ngày

Một dòng = một (user_id, item_id, date).

Tên thư mục là fact_post_contact_interactions nhưng tên file gốc lại bắt đầu bằng datathon_fact_user_ad_interactions-*. Đây là sự không khớp **cố ý giữ nguyên** từ

pipeline gốc; thí sinh vẫn đọc bằng đường dẫn thư mục như bình thường.

Cột	Kiểu	Mô tả
user_id	string	Mã người dùng
item_id	string	FK → dim_listing
date	date	Ngày
adview_count	float	Số lượt xem tin
lead_count	float	Số lượt lộ số điện thoại / email
chat_message_count	float	Số tin nhắn chat
chat_turn_count	float	Số lượt qua lại trong chat
chat_lead	float	Cờ lead phát sinh từ chat
purchased	bool	Dự đoán của Chợ Tốt về việc tin đăng đã có người mua/thuê được hay chưa. Đây là nhãn dự đoán nội bộ — có thể đúng hoặc sai.
category	int	Mã danh mục tin

► fact_user_events — Clickstream thô

Bảng lớn nhất, chiếm phần lớn dung lượng toàn bộ tập dữ liệu. Mỗi dòng = một hành vi của người dùng.

Cột	Kiểu	Mô tả
is_login	string	login / non-login
user_id	string	Mã người dùng (lưu ý: với non-login, user_id thay đổi theo từng phiên)
session_id	string	Mã phiên
event_id	string	Mã sự kiện
item_id	string	FK → dim_listing
city_name	string	Tên TP của tin (tiếng Việt)
category	int	Mã danh mục
event_type	string	Loại sự kiện (xem bảng dưới)
query	string	Truy vấn tìm kiếm (chỉ có với pageview từ search)
event_ts	timestamp	Thời điểm sự kiện
surface	string	Bề mặt UI nơi sự kiện diễn ra
position	float	Vị trí trong feed / kết quả tìm
device	string	Desktop / MSite / iOS / Android
dwell_time_sec	float	Thời gian dừng trên trang tin (giây)
is_contact	int	Cờ 1 nếu sự kiện là liên hệ
date	date	Ngày của event_ts

Giá trị	Ý nghĩa
pageview	Xem trang tin
other_interaction	TÍCH CỰC
view_phone	TÍCH CỰC — bấm xem số điện thoại
contact_chat	TÍCH CỰC — mở phiên chat
contact_zalo	TÍCH CỰC — nhấn Zalo
contact_sms	TÍCH CỰC — nhấn SMS

Các giá trị event_type.

I Quan hệ giữa các bảng

Table 2: Cardinality giữa các bảng

Quan hệ	Cardinality
<code>dim_listing</code> ↔ <code>fact_listing_snapshot</code>	1 : nhiều (theo ngày)
<code>dim_listing</code> ↔ <code>fact_post_contact_interactions</code>	1 : nhiều (theo user, ngày)
<code>dim_listing</code> ↔ <code>fact_user_events</code>	1 : nhiều (theo sự kiện)
<code>user_id</code> (events) ↔ <code>user_id</code> (interactions)	nhiều : nhiều

I Lưu ý chung

Dữ liệu được giữ **nguyên trạng (raw)**. Thí sinh cần tự đánh giá chất lượng dữ liệu (missing values, outlier, encoding...) và đề xuất phương pháp tiền xử lý phù hợp với bài toán của mình.

Hướng dẫn Truy cập & Sử dụng Dữ liệu

I Tổng quan môi trường

Do dung lượng bảng `fact_user_events` lớn (~160 GB ở dạng nguyên thủy), BTC **không** phân phối dữ liệu dưới dạng file tải về. Thay vào đó, toàn bộ dataset được lưu trên **Google Cloud Storage** và thí sinh truy cập trực tiếp từ **Google Colab**.

Quy định bắt buộc về môi trường:

- **Môi trường:** Thí sinh *được khuyến khích* chỉ sử dụng Google Colab để thao tác với dữ liệu. Việc này nhằm tối ưu tốc độ và tránh phát sinh chi phí truyền tải dữ liệu (Egress fee) cho BTC.
- **Xác thực:** Đội thi vui lòng gửi danh sách Gmail để BTC mở quyền truy cập.
- **Không tải dữ liệu về máy cá nhân:** Mọi xử lý đều thực hiện trên Colab. BTC theo dõi lưu lượng egress và sẽ thu hồi quyền truy cập nếu phát hiện tải hàng loạt ra ngoài.

I Cấu trúc dữ liệu trên Google Cloud Storage

Bucket: `gs://datathon_2026_final/`

Dữ liệu được tổ chức theo cấu trúc thư mục (object prefix) như sau:

```

1 datathon_2026_final/
2 |-- test/
3 | '-- test_users.parquet # Danh sách user_id cần du đoán
4 '-- train/
5     |-- dim_listing/ # Thông tin tin đang (40 files)
6     | |-- part-00000-....parquet
7     | '-- ...
8     |-- fact_listing_snapshot/ # Hiệu suất tin đang theo ngày (62 files)
9     | |-- part-00000-....parquet
10    | '-- ...
11    |-- fact_post_contact_interactions/ # Tương tác user x tin theo ngày (147 files)
12    | |-- part-00000-....parquet
13    | '-- ...
14    '-- fact_user_events/ # Clickstream (500 files)
15        |-- datathon_fact_user_events-00000000000000000000.parquet
16        |-- datathon_fact_user_events-00000000000000000000104.parquet
17        '-- ...

```

I Kết nối từ Google Colab

► Xác thực tài khoản

```

1 # 1. Xác thực tài khoản Google
2 from google.colab import auth
3 auth.authenticate_user()
4
5 # 2. Cấu hình đường dẫn
6 BUCKET_NAME = "datathon_2026_final"
7
8 TRAIN_PATH = f"gs://{BUCKET_NAME}/train/"
9 TEST_PATH = f"gs://{BUCKET_NAME}/test/"

```

► Đọc tập test

```

1 import pandas as pd
2
3 # GCP tu dong nhan dien thong qua credentials vua dang nhap
4 df_test = pd.read_parquet(f"{TEST_PATH}test_users.parquet")
5
6 print("Ket noi thanh cong! So luong user can du doan:", len(df_test))
7 print(df_test.head())

```

► Đọc thử một file Parquet đơn lẻ

Để xem nhanh schema và một vài dòng dữ liệu mà không tốn RAM, đọc thử một file:

```

1 single_file = (
2     f"{TRAIN_PATH}fact_user_events/datathon_fact_user_events-000000000104.parquet"
3 )
4
5 df_sample = pd.read_parquet(single_file)
6 print(f"So dong trong file: {len(df_sample)}")
7 df_sample.head()

```

► Quét toàn bộ thư mục (khuyến dùng cho big data)

Bảng fact_user_events chứa hàng trăm triệu dòng sự kiện chia thành 500 file Parquet. Để tránh lỗi tràn bộ nhớ (Out-of-Memory), nên sử dụng pyarrow.dataset để quét thư mục và chỉ lọc lấy dữ liệu cần thiết.

```

1 import pyarrow.dataset as ds
2
3 folder_path = f"{TRAIN_PATH}fact_user_events/"
4
5 # Lenh nay chi tao connection (mapping) toi cac file,
6 # KHONG load het vao RAM
7 dataset = ds.dataset(folder_path, format="parquet")
8
9 print(f"He thong da nhan dien duoc {len(dataset.files)} files trong thu muc.")
10 print("Lay thu 5 dong dau tien:")
11 display(dataset.head(5).to_pandas())

```

Notebook hướng dẫn chính thức của BTC: thí sinh nên đọc kỹ Colab notebook ([Link](#)) do BTC cung cấp trước khi bắt đầu. Notebook chứa các đoạn code mẫu được test sẵn trên môi trường Colab.

I Khuyến nghị về xử lý dữ liệu lớn

Với dung lượng fact_user_events lên đến ~160 GB ở dạng raw, các đội thi cần lưu ý:

- **Lọc theo cột:** chỉ đọc các cột cần thiết cho mỗi bước xử lý (parameter columns=[...] của pyarrow/pandas).
- **Lọc theo điều kiện:** push-down filter qua pyarrow.compute để giảm số dòng load vào RAM.
- **Pre-aggregate sớm:** tổng hợp về cấp user / item / ngày trước khi join, không thao tác trực tiếp ở cấp event.

- **Tận dụng partition theo file:** mỗi file Parquet có thể xử lý độc lập — có thể loop từng file, ghi kết quả trung gian xuống Drive / GCS.

Điều khoản sử dụng dữ liệu

Điều khoản sử dụng (bắt buộc đồng ý):

Dữ liệu được Chợ Tốt cung cấp *độc quyền* cho mục đích tham gia Datathon 2026. Bằng việc đăng ký dự thi và truy cập bucket, thí sinh đồng ý:

1. **Chỉ sử dụng dữ liệu cho mục đích tham gia cuộc thi.** Không sử dụng cho bất kỳ mục đích nào khác — bao gồm nhưng không giới hạn: nghiên cứu cá nhân, dự án thương mại, công bố học thuật, huấn luyện mô hình bên thứ ba, hay bất kỳ ứng dụng nào ngoài phạm vi Datathon 2026.
2. **Không chia sẻ, tái phân phối hay công khai dữ liệu** dưới mọi hình thức (tải xuống, sao chép ra bucket cá nhân, đẩy lên GitHub/Kaggle public, gửi cho bên thứ ba...).
3. **Không sao lưu, lưu trữ vĩnh viễn dữ liệu trên thiết bị/dịch vụ cá nhân.** Sau khi cuộc thi kết thúc, mọi bản sao dữ liệu (nếu có) phải được xóa.
4. **Không cố gắng giải ẩn danh (de-anonymize)** các định danh người dùng / tin đăng / người bán.
5. **Tôn trọng quyền sở hữu trí tuệ** của Chợ Tốt đối với toàn bộ tập dữ liệu.

Vi phạm bất kỳ điều khoản nào ở trên sẽ dẫn tới việc *loại bỏ đội thi*, thu hồi giải thưởng (nếu đã trao), và — trong trường hợp nghiêm trọng — BTC có quyền chuyển vụ việc tới các bộ phận pháp lý liên quan của Chợ Tốt và VinUniversity.

Đề Bài

I Bối cảnh kinh doanh

Bạn là nhà khoa học dữ liệu tại Chợ Tốt — nền tảng C2C bất động sản hàng đầu Việt Nam. Doanh nghiệp cần xây dựng **hệ khuyến nghị** đẩy đúng tin đăng đến đúng người dùng, vừa tối ưu *Contact Rate* (CR) — tỷ lệ người dùng thực sự liên hệ sau khi xem tin — vừa giữ *sức khoẻ marketplace*: công bằng giữa môi giới và chính chủ, đa dạng phân khúc, và cơ hội cho tin mới.

Đề thi gồm **hai phần độc lập** nhưng bổ trợ chặt chẽ cho nhau: Phần 1 là một bài *Trực quan hoá và Phân tích Dữ liệu* mang tính kể chuyện business, Phần 2 là bài *xây dựng mô hình gợi ý top-10 tin đăng* cho mỗi người dùng. Mỗi đội thi phải hoàn thành cả hai phần.

I Phần 1 — Trực quan hoá và Phân tích Dữ liệu

Khám phá bộ dữ liệu để tìm ra các *insight có ý nghĩa kinh doanh* cho hệ thống Chợ Tốt BĐS. Đề bài không quy định trước các câu hỏi cụ thể — BTC chủ ý để ngỏ để các đội thi tự lựa chọn góc nhìn và thể hiện tư duy phân tích của mình.

Bài làm Phần 1 thường bao gồm cả thành phần trực quan (biểu đồ, dashboard, bản đồ...) và thành phần diễn giải (giải thích, kết luận, đề xuất hành động). Cách kể chuyện, lựa chọn câu hỏi, mức độ định lượng của các phát hiện và mức độ kết nối với hoạt động kinh doanh thực tế của Chợ Tốt đều là các yếu tố BGK quan tâm.

► Một vài gợi ý mở (không bắt buộc)

Dưới đây là một số gợi ý mở để khơi mào ý tưởng. Đây *không phải checklist*; các đội hoàn toàn có thể chọn các góc nhìn hoàn toàn khác:

- Hành trình từ *xem tin* đến *liên hệ* của một người mua/thuê BĐS điển hình.
- Sự khác biệt giữa các phân khúc (thuê / mua, chính chủ / môi giới, các category 1010–1050).
- Các yếu tố ảnh hưởng đến xác suất một tin đăng phát sinh liên hệ.
- Vai trò của vị trí, thiết bị, thời điểm, vòng đời tin...
- Các tin đăng có hiệu suất cao bất thường — và đặc trưng chung của chúng.
- Hành vi của người dùng mới (cold-start) so với người dùng đã có lịch sử.

Phần 2 — Mô hình Gợi ý (Recommender System)

► Định nghĩa bài toán

Cho lịch sử quan sát đầy đủ của một người dùng trên Chợ Tốt BDS đến hết **09/04/2026**, hãy dự đoán **top-10 item_id phân biệt** mà người dùng đó sẽ có **tương tác tích cực** trong khoảng **10/04/2026 – 07/05/2026**, xếp hạng từ khả năng cao nhất xuống thấp nhất.

Tương tác tích cực được định nghĩa chính xác bằng:

Tương tác tích cực được định nghĩa là:

$$\text{fact_user_events.event_type} \in \{\text{view_phone}, \text{contact_chat}, \text{other_interaction}, \text{contact_zalo}, \text{contact_sms}\}.$$

Tập tin được phép dự đoán: mỗi người dùng test phải dự đoán tối đa **10 item_id phân biệt**, lấy từ tập tin có mặt trong `train/dim_listing/`. Các item_id nằm ngoài tập này sẽ bị loại bỏ trước khi chấm điểm.

► Nhiệm vụ cốt lõi

Với mỗi `user_id` trong tập test, các đội thi cần dự đoán **top-10 item_id** mà người dùng có khả năng cao nhất sẽ *liên hệ* trong cửa sổ đánh giá. Định dạng output: `user_id, rank, item_id`.

Đề bài không quy định kiến trúc, mô hình hay chiến lược cụ thể. Các đội tự lựa chọn cách tiếp cận và **trình bày đầy đủ trong báo cáo**: vì sao chọn cách đó, các giả định, các bước tiền xử lí, đặc trưng được sử dụng, cách huấn luyện và đánh giá nội bộ.

► Yêu cầu kép: chính xác + lành mạnh

Một hệ khuyến nghị tốt cho marketplace không chỉ đo bằng accuracy. BGK kỳ vọng các đội thi có *ý thức rõ ràng* về tác động của mô hình lên hệ sinh thái Chợ Tốt.

Khuyến khích các đội suy nghĩ và trình bày trong báo cáo về *trade-off* giữa độ chính xác (Contact Rate / Recall / NDCG) và các tiêu chí marketplace health như *fairness, diversity, freshness, coverage*. Việc minh hoạ trade-off bằng các thử nghiệm so sánh (ví dụ: với và không có cơ chế cân bằng) là một cách trình bày được đánh giá cao — nhưng cụ thể làm thế nào là tự do của mỗi đội.

► Tư duy triển khai

Báo cáo cũng nên thể hiện một mức độ “tư duy production” nhất định: nếu mô hình này được triển khai thực tế tại Chợ Tốt thì cần lưu ý gì? Mức độ chi tiết và sự tỉnh táo về các vấn đề này là một tín hiệu tích cực với BGK.

► Định dạng file dự đoán

Một file CSV duy nhất, mã hoá **UTF-8 (không BOM)**, đặt tên `submission.csv`. Định dạng long:

`user_id,rank,item_id`

Cột	Kiểu	Ràng buộc
<code>user_id</code>	string	Phải có trong <code>test/test_users.parquet</code>
<code>rank</code>	int	$1 \leq \text{rank} \leq 10$; mỗi (user,rank) là 1 dòng
<code>item_id</code>	string	Phải có trong <code>train/dim_listing/</code> (nếu không sẽ bị drop)

► Ràng buộc bài nộp

1. **Không leak tương lai.** Chỉ được huấn luyện trên dữ liệu có `date` $\leq 09/04/2026$ (và `event_ts` $< 10/04/2026$). Ground truth (10/04 – 07/05) không được public và không được phép sử dụng để train.
2. **Không dùng dữ liệu ngoài.** Mô hình chỉ được huấn luyện từ 4 bảng trong `train/`. Không được sử dụng dataset BDS bên ngoài, profile người dùng từ nguồn khác, embedding pretrained trên dữ liệu Chợ Tốt rò rỉ, hay API ngoài.
3. **Không reverse-engineer định danh.** Mọi nỗ lực giải ẩn danh đều bị nghiêm cấm.
4. **Số lần nộp:** 1 lượt / đội / ngày UTC.
5. **Tính tái lập (Reproducibility).** Đính kèm toàn bộ mã nguồn. Đặt random seed khi cần thiết. Top winners phải tái tạo lại submission cuối cùng với sai số đủ nhỏ.

Tiêu chí Đánh giá

I Triết lý chấm

Vòng 2 là một bài thi *mở*: BGK không phát hành barem chi tiết theo từng đầu mục và không kỳ vọng tất cả các đội đi theo một khuôn mẫu giống nhau. Thay vào đó, BGK đánh giá bài làm trên một số trục giá trị tổng thể, ưu tiên các đội có cách tiếp cận *sáng tạo, có cơ sở và có chiều sâu*.

I Các trục đánh giá chính

Table 3: Các trục đánh giá Vòng 2

Trục	BGK sẽ nhìn vào điều gì?
Chất lượng insight & kể chuyện dữ liệu	Bài phân tích có <i>nói lên điều gì có ý nghĩa</i> với hoạt động kinh doanh BĐS của Chợ Tốt không? Các phát hiện có được hỗ trợ bằng số liệu cụ thể không? Câu chuyện có mạch lạc và đáng nhớ không?
Thiết kế giải pháp	Cách tiếp cận mô hình có <i>hợp lý với bài toán</i> không? Các lựa chọn về feature, candidate generation, ranking, re-ranking... có cơ sở không? Các trade-off (ví dụ accuracy vs marketplace health) có được suy nghĩ thấu đáo không?
Hiệu suất mô hình	Vị trí trên Kaggle leaderboard (Recall@10 là chỉ số chính, NDCG@10 dùng tie-break). BGK so sánh kết quả với baseline để xác định mức độ “ <i>thực sự học được</i> ” của mô hình.
Marketplace health	Bài nộp có ý thức về sức khỏe marketplace không? (Coverage, exposure cho tin mới và long-tail, độ tập trung của traffic...). Đội có dám <i>đánh đổi một phần accuracy</i> để giữ sức khỏe hệ thống không, và lập luận có thuyết phục không?
Tính khả thi triển khai	Mức độ “ <i>tư duy production</i> ” của báo cáo: kiến trúc serving, re-training, abuse & risk, failure mode... Sự tỉnh táo về các rủi ro thực tế quan trọng hơn việc liệt kê đầy đủ.
Chất lượng trình bày	Báo cáo có dễ theo dõi, biểu đồ có chuyên nghiệp, ngôn ngữ có phù hợp với đối tượng đọc (mix giữa business và kỹ thuật) không?

Trọng số chi tiết giữa các trục *không* được công bố trước. BGK sẽ chấm dựa trên tổng thể, nhưng nhìn chung *chất lượng insight, thiết kế giải pháp* và *hiệu suất mô hình* chiếm phần lớn trọng số. Marketplace health và tư duy triển khai là các yếu tố *tạo khác biệt* giữa các bài có chất lượng kỹ thuật tương đương.

I Chỉ số leaderboard

Bài nộp được chấm trên Kaggle bằng hai chỉ số:

Chỉ số chính: Recall@10. Với người dùng u , đặt R_u là danh sách dự đoán (độ dài ≤ 10) và G_u là tập `item_id` ground truth của u :

$$\text{Recall@10}(u) = \frac{|R_u \cap G_u|}{|G_u|}.$$

Điểm trên bảng xếp hạng là trung bình Recall@10 trên toàn bộ người dùng test.

Chỉ số phụ (tie-breaker): NDCG@10. Với độ liên quan nhị phân:

$$\text{DCG@10}(u) = \sum_{i=1}^{10} \frac{\mathbf{1}[R_u^{(i)} \in G_u]}{\log_2(i+1)}, \quad \text{IDCG@10}(u) = \sum_{i=1}^{\min(10, |G_u|)} \frac{1}{\log_2(i+1)},$$

$$\text{NDCG@10}(u) = \frac{\text{DCG@10}(u)}{\text{IDCG@10}(u)}.$$

Public vs Private leaderboard. Trong suốt thời gian thi đấu, public leaderboard được tính trên một *slice nhỏ* của tập ground truth và chỉ mang tính tham khảo. Xếp hạng cuối cùng được quyết định bởi *private leaderboard*, được BTC công bố sau khi cuộc thi đóng.

I Điều kiện loại bài

Bài nộp sẽ bị **loại toàn bộ** nếu vi phạm bất kỳ ràng buộc nào sau đây:

1. Sử dụng dữ liệu trong cửa sổ ground truth (`event_ts` $\geq$ 10/04/2026) dưới mọi hình thức;
2. Sử dụng dữ liệu ngoài bộ dữ liệu được cung cấp;
3. Không đính kèm mã nguồn hoặc kết quả không thể tái lập;
4. Sử dụng dữ liệu sai mục đích (xem điều khoản sử dụng ở phần Hướng dẫn Truy cập Dữ liệu).

Hướng dẫn Nộp bài

I Checklist nộp bài

Mỗi đội cần hoàn thành và nộp đầy đủ các mục sau, theo *hai mốc deadline* riêng biệt:

#	Hạng mục	Kênh nộp	Deadline
1	File <code>submission.csv</code>	Kaggle	23h59 ngày 21/05/2026
2	GitHub + Bài thuyết trình	Form Vòng Chung kết	23h59 ngày 22/05/2026

► Nộp kết quả dự đoán trên Kaggle

Link Kaggle: [Link](#)

Deadline: 23h59 ngày **21/05/2026** (giờ Việt Nam).

Link Kaggle: *[placeholder — BTC sẽ cập nhật sau]*

Đảm bảo file `submission.csv` tuân thủ *đúng cấu trúc* đã quy định:

- Đúng định dạng cột `user_id`, `rank`, `item_id`;
- Mỗi user có tối đa 10 dòng, $1 \leq \text{rank} \leq 10$;
- Cặp (`user_id`, `rank`) duy nhất; cặp (`user_id`, `item_id`) duy nhất trong phạm vi 1 user;
- Mã hoá UTF-8 (không BOM); dung lượng ≤ 100 MB.

File không đúng định dạng sẽ bị từ chối bởi hệ thống Kaggle.

Kết quả Private Test: BTC sẽ *release kết quả trên private test* vào ngày **22/05/2026**. Public Leaderboard chấm trên một slice nhỏ trong suốt thời gian thi đấu chỉ mang tính tham khảo — xếp hạng cuối cùng được quyết định bởi Private Leaderboard.

► Bài thuyết trình

Mỗi đội nộp **link bài thuyết trình** (Canva, PowerPoint hoặc PDF) cùng với báo cáo.

Quy định trình bày tại Vòng Chung kết:

- Mỗi nhóm trình bày trong **đúng 10 phút**. Ban tổ chức sẽ *bấm giờ* và yêu cầu dừng khi hết thời gian.
- Nội dung trình bày tự sắp xếp, song nên bao phủ cả Phần 1 (insight) và Phần 2 (mô hình + trade-off).
- Sau phần trình bày là phiên Q&A với ban giám khảo (thời gian sẽ được BTC thông báo).

Đảm bảo link bài thuyết trình đặt ở chế độ *public* hoặc cấp quyền xem cho BTC.

► Form nộp bài thi Vòng Chung kết

Deadline: 23h59 ngày **22/05/2026** (giờ Việt Nam).

Link form: datathon.site/submit

Form yêu cầu:

- Upload file báo cáo (PDF);
- Link GitHub repository;
- **Link bài thuyết trình** (Canva / PPTX / PDF);